



Detección de Derroche Energético

Marzo 2026



Detección de Derroche Energético

- Proyecto orientado a mejorar la eficiencia energética en entornos educativos
- Uso de sensores IoT (temperatura, humedad, aperturas, meteo) para capturar el comportamiento del aula
- Desarrollo de un sistema de datos completo: ETL + modelado + (API+APP) + dashboard
- Aplicación de Machine Learning y Redes Neuronales para predecir situaciones de derroche
- **Enfoque predictivo:** detección de derroche en la siguiente hora ($t+1$)
- Sistema diseñado para:
 - Detectar ineficiencias energéticas
 - Reducir consumo
 - Facilitar la toma de decisiones



Descripción paso a paso

1. EDA

- a. Análisis del dataset
- b. Separación de datos en tipo de sensores
- c. Para cada sensor:
 - i. Análisis de datos y extracción de características
 - ii. Limpieza de datos , eliminación de nulos y valores imposibles
 - iii. Correlación entre sensores del mismo tipo
 - iv. Interpolación de valores en el caso de meteorología Mislata
 - v. Cálculo de valores horarios
- d. Generación de modelo ML para calculo de temperatura del sensor de calefacción mediante el del aula.

2. ETL de extracción, transformación y guardado de datos de los sensores

3. Red Neuronal de predicción de “Derroche”



4. Generación de API de consumo y APP de uso del modelo de “derroche”

5. Dashboard en Grafana de sensores

EDA y Datos

Problemas detectados

- Presencia de valores no numéricos (“*unavailable*”) → convertidos a NaN
- **Valores faltantes (missing data)** por fallos de comunicación
- **Frecuencia irregular** (datos por eventos, no series continuas)
- Existencia de **gaps largos** que pueden distorsionar el análisis
- Algunos sensores con **datos insuficientes o defectuosos**





EDA y Datos

Correlación entre sensores

- Correlación muy alta entre sensores de temperatura y humedad (≈ 0.99)
- Indica **redundancia de información**

Decisión:



- Seleccionar el sensor con mayor calidad y cantidad de datos
- Reducir dimensionalidad sin perder información relevante



Feature Engineering


Generamos:

- Sensor virtual de ventanas
- Diferencias interior/exterior
- Variables cíclicas
- ML temperatura calefacción



Tenemos:


- Dataset desbalanceado
- Alta correlación entre características.



Modelos y Evaluación

Modelado

- Problema de **clasificación binaria**:
 - 0 → No derroche
 - 1 → Derroche
- Se entrenan múltiples arquitecturas de **red neuronal**:
 - [16, 1]
 - [32, 16, 1]
 - [64, 32, 16, 1]
 - [128, 64, 32, 1]
 - entre otras
- Configuración:
 - Función de pérdida: *binary_crossentropy*
 - Optimizador: *Adam*
 - 50 épocas con *EarlyStopping*
 - Normalización con *StandardScaler*




Modelos y Evaluación

Problema clave: dataset desbalanceado

- Muy pocos casos de derroche frente a casos normales
- Métricas como **accuracy** no son representativas dado el desbalance extremo de datos.

Soluciones aplicadas:

- Uso de **class_weight** (penaliza más errores en clase minoritaria) en el entrenamiento con 70/30 en train/validación y 80/20 en train/test
- Aunque el **F1-score** es una métrica habitual en clasificación binaria, en este caso no es la más adecuada como criterio principal.
- Se opta por un enfoque basado en el **equilibrio entre precisión y sensibilidad**, priorizando la **sensibilidad (recall)**.
- Esto se debe a que el objetivo del sistema es **maximizar la detección de derroches reales (TP)**, incluso a costa de aumentar los falsos positivos.
- En consecuencia, se da mayor peso a minimizar los **falsos negativos (FN)**, ya que estos representan situaciones de derroche no detectadas.



Modelos y Evaluación

Métricas utilizadas

- **Recall (Sensibilidad)** → capacidad de detectar derroches
- **Precision** → calidad de las alertas
- **F1-score** → equilibrio entre precision y recall

Optimización de umbral

- No se usa threshold fijo (0.5)
- Se busca el umbral óptimo que maximiza el F1-score

Beneficio:

- Mejora el rendimiento del modelo adaptándolo al problema

Resultados obtenidos

- Modelos con alto recall → detectan más derroches pero más falsos positivos
- Modelos equilibrados → menor error global
- Modelos conservadores → menos falsos positivos pero pierden casos reales

Modelo	TP	FN	FP	Recall	Precision	
[16,1]	21	4	269	0.84	0.07	Alto recall
[64,32,16,8,1]	20	5	299	0.80	0.06	
[64,32,16,1]	16	9	180	0.64	0.08	
[32,64,32,16,1]	11	14	91	0.44	0.11	Equilibrado
[32,16,1]	10	15	91	0.40	0.10	
[128,64,32,1]	6	19	53	0.24	0.10	
[128,32,1]	4	21	9	0.16	0.31	Conservador

APP

Se ha creado una API y una APP don Flet para consumo del modelo:

Prediccion de derroche energetico

Introduce los datos

Seleccionar fecha 30/03/2026 Hora 11:00 Modelo a

Temperatura interior (C) 21.0 Humedad interior (%) 55.0
Temperatura exterior (C) 16.5 Humedad exterior (%) 34.8 Viento (km/h) 2.2
Direccion viento 294.5 Elevacion solar -7.7

Actualizar Meteo/Sol Borrar datos Datos meteo/sol actualizados.

Programacion de calefacción

Cargar programacion de calefacción

Programacion precargada desde calefacción.json.

Horario	L	Ma	Mi	J	V	Sa	Do
06:59	T21.9	T21.9	T21.9	T21.9	T21.9	T21.9	T21.9
11:00	422.0	422.0	422.0	422.0	422.0	422.0	422.0
11:02	T21.9	T21.9	T21.9	T21.9	T21.9	T21.9	T21.9
16:00	422.0	422.0	422.0	422.0	422.0	422.0	422.0
16:02	T21.5	T21.5	T21.5	T21.5	T21.5	T21.5	T21.5
18:00	421.6	421.6	421.6	421.6	421.6	421.6	421.6
18:02	T21.9	T21.9	T21.9	T21.9	T21.9	T21.9	T21.9
20:40	422.0	422.0	422.0	422.0	422.0	422.0	422.0
04:00	T4.0	T4.0	T4.0	T4.0	T4.0	T4.0	T4.0
05:00	15.0	15.0	15.0	15.0	15.0	15.0	15.0



Predcir

Predcir multihora

Resultados

Prediccion multihora completada desde 30/03/2026 11:00

Hora	Prediccion	Confianza	Probabilidad	Threshold
11:00	Sin incidencia	99.74%	0.26%	95.00%
12:00	Sin incidencia	99.96%	0.04%	95.00%
13:00	Sin incidencia	99.99%	0.01%	95.00%
14:00	Sin incidencia	100.00%	0.00%	95.00%
15:00	Sin incidencia	100.00%	0.00%	95.00%
16:00	Sin incidencia	99.99%	0.01%	95.00%

Dashboard





Conclusiones y aprendizaje

Conclusiones

- El modelo permite **anticipar situaciones de derroche ($t+1$)** pero el desbalanceo de datos complica el generar un modelo preciso.
- La calidad del dato ha sido clave:
 - Limpieza, interpolación y agregación horaria
 - Eliminación de sensores redundantes
- El dataset presenta **alto desbalanceo**, lo que condiciona:
 - Elección de métricas
 - Diseño del modelo
- Se ha tomado una decisión alineada con negocio:
 - Priorizar **recall (sensibilidad)**
 - Minimizar falsos negativos (no perder derroches)

Aprendizajes clave

- Accuracy puede ser **engañoso en problemas desbalanceados**
- El umbral de decisión es tan importante como el modelo
- Hay que seleccionar las métricas del modelo según el problema planteado aunque a priori usaríamos otras.



Próximos pasos

Datos

- Generación de **datos sintéticos** para balancear clases
- Incorporar más contexto:
 - ocupación del aula
 - calendario (clases, horarios reales)
- Mejora de calidad:
 - detección automática de sensores defectuosos

Sistema

- Integración con **Home Assistant**:
 - alertas automáticas en tiempo real, extracción de los datos de forma directa.
- Aprendizaje continuo:
 - reentrenamiento con nuevos datos

Gracias :-)

